

# Engenharia de Dados em Português

Documento de contexto do projeto — para uso como referência em conversas futuras

---

## Visão geral

Projeto pessoal, público, hospedado no GitHub, com o objetivo de documentar e organizar o aprendizado em engenharia de dados de quem está entrando na área — escrito por alguém que também está nesse caminho, não por um "especialista" de fora olhando de cima.

O criador do projeto é engenheiro eletricista, migrando para dados por conta própria. Já estudou/estuda Python, SQL, Airflow e Git, e no momento está avançando em nuvem. Tem projetos próprios em andamento.

## Motivação — o problema real que o projeto resolve

Não é falta de conteúdo sobre engenharia de dados na internet. É o oposto: existe conteúdo demais, majoritariamente em inglês, espalhado sem um roteiro claro de "comece por aqui". Quem não tem inglês fluente enfrenta uma barreira ainda maior — fica sem acesso à maior parte do material de qualidade que existe sobre o assunto.

Além disso, listas de recursos existentes (ex.: awesome-data-engineering) são boas para indicar onde estudar, mas raramente explicam o essencial: por que cada ferramenta existe, que problema real ela resolve, e o que existia antes dela que não era suficiente. As pessoas aprendem a operar ferramentas sem entender a lógica por trás delas.

Hoje, com IA, escrever código deixou de ser o gargalo. O que continua sendo difícil — e o que continua importando de verdade — é entender o raciocínio por trás de cada peça do ecossistema de dados.

## Princípios do projeto

- Totalmente em português — não é tradução automática, é escrita pensando em quem tem português como língua nativa.
- Prioridade máxima para fontes em português. Quando não existir substituto em português, linkar conteúdo em inglês mesmo assim (e, quando possível, buscar contato com criadores — incluindo criadores indianos de conteúdo técnico — para pedir permissão de tradução/dublagem/legenda).
- Conhecimento técnico deveria ser gratuito. Esse é o princípio-base do projeto.
- Narrativa, não lista de tecnologias. Cada módulo conta uma história: por que aquilo surgiu, que problema resolveu, o que existia antes que não era suficiente, trade-offs, e só então um exemplo prático.
- Tom de voz autêntico, sem "português corporativo" (nada de "vamos explorar sinergicamente o ecossistema de dados"). Linguagem direta, real, sem pretensão de curso engessado.

- Inspiração estrutural (não de conteúdo) no livro *Fundamentals of Data Engineering* (Reis & Housley) — especialmente na forma como o livro constrói a evolução histórica antes de citar ferramentas específicas.

## Formato da narrativa

Estrutura em camadas: primeiro uma narrativa progressiva organizada em módulos (cada módulo explica sua origem histórica, o problema que resolve e como se conecta ao próximo). Depois, como camada complementar, um glossário com links cruzados apontando de volta para os trechos da narrativa onde cada conceito foi explicado — meio-termo entre "livro que se lê do início ao fim" e "enciclopédia que se consulta pontualmente".

Roteiro esperado para cada módulo: o que é → que problema resolve → o que existia antes e por que não era suficiente → trade-offs / quando não usar → exemplo prático.

## Estrutura de pastas (em construção)

Primeiro módulo já nomeado: pasta **que-porra-e-essa**, contendo os arquivos que explicam o que é dado, o que é engenharia de dados e os conceitos-chave iniciais — o ponto de partida de tudo, sem jargão nem discurso corporativo.

A estrutura completa de pastas (módulos seguintes: fundamentos, SQL, Python, orquestração, cloud, arquitetura, etc.) ainda está sendo desenhada à medida que os módulos forem escritos.

## Fluxo de trabalho

- Escrita local no Obsidian (markdown puro, sem lock-in) — aproveitando links bidirecionais para já ir construindo o glossário interconectado, e o grafo visual para enxergar como os conceitos se relacionam.
- Versionamento e publicação via Git/GitHub.
- Cuidado para manter a sintaxe markdown compatível entre Obsidian e GitHub puro (evitar sintaxes específicas de plugin que não renderizam fora do Obsidian), já que nem todo leitor vai abrir o conteúdo no Obsidian.
- Projeto pensado para ser colaborativo no futuro — qualquer pessoa poderá contribuir com módulos ou sugestões de recursos em português; o criador do projeto atua como curador, garantindo que tudo siga a mesma tese central ("por que isso existe" antes de "como usar isso").

## Ritmo e divulgação

Projeto sem prazo — desenvolvido aos poucos, sem pressa, já que por natureza é um projeto que estará sempre em construção. A divulgação pública (ex.: LinkedIn) só deve acontecer quando já houver uma quantidade sólida de material publicado, para causar uma primeira impressão de projeto consistente, e não de repositório abandonado pela metade.

## Como usar este documento

Este PDF resume o contexto, os princípios e as decisões já tomadas sobre o projeto até este ponto. Ele serve como referência para retomar o trabalho em conversas futuras — para produção de novos módulos, revisão de texto, definição de estrutura, ou qualquer outra frente relacionada ao projeto — sem precisar reexplicar o contexto do zero.